予測から介入へ — 公開研究の実習版

無料公開研究書籍 / 2026-10-24

全4章・執筆中。本全体とManagerは未完成。モデルの予測優位・人への便益は未実証。各章は研究の進行順で、前章の未実施は当時の状態、最新の比較結果は第4章にある。

1. AIによる説得を、どこまで確かめられるか

2. 「変わりたい」を、行動の変化と取り違えない

3. 同じ発話が十行あるとき — 会話データを評価に使う前に

4. 学習が動いても、予測が改善したとは限らない

出典・手順・分母・未測定・陰性結果を残すための実習集。公開原著の転載や、専門的支援の代替を目的とするものではない。

原稿の固定commit: 66e953e9c298e3acc5eb9fd3d61f13d9dc70b4ef

AIによる説得を、どこまで確かめられるか

無料公開書籍『予測から介入へ』の実習章。2026-10-24版。行動シミュレーションやAI介入を学び始めるエンジニアが、公開研究を読み、実行し、結果の意味を説明できることを目指す。書籍全体は執筆中。本章は原著の転載ではなく、訂正公開資料を用いた独自の解説と再現記録である。

出発点を一つの表に置く

AIと話した後、人の信念は変わるのだろうか。変わったとして、それは会話直後だけのことだろうか。

Thomas Costello、Gordon Pennycook、David Randの研究は、この問いを実際の参加者との対話で調べた。本人が挙げた陰謀説についてAIと対話する条件と、無関係な話題についてAIと対話する条件を比較している。私たちは、その研究の2026年訂正パッケージを使い、解析コードを動かした。

原著の数字を紹介する前に、何を再現したのかを明確にする。今回、新しい参加者を募集したわけではない。AIに新しい返答を生成させてもいない。公開された数値データに、著者が公開した解析コードを適用し、保存済みの結果と比較した。

この作業を終えると、「AIは説得できる」という大きな言葉を、対象、比較、単位、期間のある問いへ分解できるようになる。

意見、行動、その後の生活を分けて考える

文章を読んで賛成したことと、実際に行動したことは違う。行動しても、それが続くとは限らない。続いたとしても、負担や依存が増えているかもしれない。

研究を読むときには、まず何を測ったのかを探す。この研究の主要な数値は、ある信念が正しいと本人がどの程度確信しているかを表す0〜100の回答だった。真偽判定の正答率でも、苦しみが減った割合でもない。

行動変容を通じて苦しみの低減を目指すなら、この区別は研究を前へ進めるために必要になる。意見変化の研究からは、その測り方を学ぶ。行動や苦しみについては、対応する別の観測を用意する。一つの数字にすべてを背負わせる必要はない。

訂正資料から解析対象を確認する

訂正版の主要解析表には2,094行、54列がある。Study1は748行、Study2の二つのwaveは584行と762行だった。事後の主要回答は50行で欠けている。

ここで2,094人全員について同じ解析ができると思ってはいけない。主要な回帰モデルが使う完全caseは、Study1が738行、Study2を合わせたものが1,306行になる。解析前の対象者数と、モデルへ入った人数の両方が必要だ。

公開資料には、除外や重複した試行を追う表もある。公開された疑似識別子を使えば、この版の中でどの記録がどの解析対象に対応するかを調べられる。現実の人物を調べ直したり、外部の情報へ結びつけたりする必要はない。

別の列では、-999が「該当しない」という意味を持っていた。欠測とは別の回答である。数値の形をしていることだけを理由に、平均へ入れたり0へ置き換えたりすると、解析の意味が変わってしまう。

同じ式でも、処理順が結果を変える

主要な回帰式は、事後のconfidenceを、割付条件、中心化した事前confidence、その交互作用から説明するものだった。

```
Post_Belief_Specific ~ ExperimentalCondition * Pre_Belief_Specific_c
```

中心化とは、各人の事前値から、その集団の平均事前値を引くことだ。このコードでは、欠測した事後回答を除く前のscreened cohortで平均を計算する。その後、回帰に必要な値がそろった行を使う。

交互作用があるため、treatmentの係数は、この平均事前値における条件差を表す。完全caseだけで平均を取り直せば、係数を読む基準点が変わる。「同じ回帰を使った」という説明だけでは、再現方法として足りない理由がここにある。

再計算では、Study1のtreatment係数が約-16.555、95%区間が[-19.515, -13.595]、Study2 pooledでは約-12.836、区間が[-15.354, -10.318]となった。単位は本人報告のslider pointである。全員が同じだけ変わったという意味ではない。

上流の結果6表、合計45行を全cellで比較し、数値差は最大約7.4×10^-13だった。ただし、この45行には過去の公表値やコード内の定数も含まれる。すべてを独立に推定し直したと説明すると、再現した範囲を広く見せてしまう。

追跡を確かめるには、環境も記録する

会話直後の変化を確かめた後は、追跡結果を見る。上流の検証プログラムは、10日追跡について630人・1,883観測、2か月追跡について489人・1,951観測を使う混合モデルを再計算する。

私たちの最初の検証は、Rの依存パッケージが足りず停止した。追加後にも、自由度の計算に必要なパッケージの不足があり、区間とp値が合わなかった。必要な依存を補うと、元コードや期待値を変更せずに、上流の7部の検証が通った。

R本体は上流のlockにある4.5.0に対し、今回使ったのは4.5.3だった。したがって、数値を許容差内で再現したことと、同じ環境を完全復元したことを区別する。

また、追跡に回答した人への条件付けや脱落は残る。直後と追跡の差が統計的に有意でないことだけで、効果が完全に等しいと証明できるわけでもない。

予測するモデルは、まず単純な方法と比べる

この公開資料から、別の小さな研究も準備した。事前confidenceと割付条件の二つだけを使い、事後confidenceを予測する研究である。個人の属性や会話本文は入力しない。

Study1から結果値で選ばない128行を学習候補に固定し、Study2aをdevelopmentに使った。584行のうち実際の事後回答がある568行で、予測誤差を比べた。

事前値をそのまま予測にする方法の平均絶対誤差は14.778 point。128行の平均を使う方法は22.202 point。128行で学習したOLSは15.625 pointだった。一方、二乗誤差の平方根では、事前値維持が25.551、OLSが21.655となった。

指標によって順序が変わる。今回のprimaryは平均絶対誤差と先に決めていたので、OLSの数字が良く見える二乗誤差へ、後から主役を入れ替えない。モデル開発では、こうした小さな判断が結論を左右する。

この時点で新しいLLMやadapterを採点したわけではない。別に固定したevaluation waveも、このbaseline比較では採点していない。ただし、公開データであり、原著の解析や品質確認にも曝露している。完全に未知の評価資料とは呼べない。

学習データに使える部分を見極める

このパッケージの会話本文は、元と同じ単語数のneutral placeholdersへ置換されている。公開されているからといって、説得会話の学習用にそのまま使えるわけではない。

数値のconfidence予測には使える可能性がある。一方で、相手に合う説明を作る能力や、圧力・依存を避ける能力を学習するには、それに対応した資料が要る。集計されたstrategy ratingを、個々の応答に付いた評価として扱うこともできない。

次の独自モデル研究では、既存Qwenと標準PEFT／TRLを使う単一LoRAの比較を設計した。学習用入力は準備したが、新しいsource専用のcaller、テスト、CI、終了監視の確認はまだ残っている。学習済みと計画済みを分けておくことも、読者が実験を追うための情報になる。

自分で確かめる実習

最初に訂正版のREADME、LICENSE、MANIFESTを読む。データ、コード、論文・図の権利は別である。完全ZIPは約676MBなので、必要な容量を確認する。取得した版とファイルのハッシュを保存し、元データを変えない別の作業copyを用意する。

上流のR環境を用意したら、パッケージのrootで次を実行する。

```
Rscript --vanilla scripts/build_results.R
Rscript --vanilla scripts/validate_analysis.R
```

一つ目は主要な解析表を再計算する。二つ目は主要モデル、表、参加者フロー、追跡モデルなどを検証する。保存済みcausal forest集計の確認も含むが、forestを新しく学習するコマンドではない。全archiveや全図の再現とも異なる。

読み終えたら、次の四点を自分の言葉で説明してほしい。何を変えた条件と何を比較したのか。結果の単位は何か。誰の結果が欠けているか。そして、自分が実際に再現した範囲はどこまでか。

出典・再現記録

- Costello, Pennycook, Rand, Durably reducing conspiracy beliefs through dialogues with AI。

- Dryad訂正公開資料、dataset136984/version8。

- Zenodo完全再現パッケージ、record22754984/version1.0。コードは著者のMIT License、関連Dryad dataはCC0、論文・図等は別の権利条件。上の式とコマンドは同パッケージを参照。

- 今回の実行・照合receipt。

- 次の数値forecast研究設計。

- 無料公開書籍の構成と現在の公開範囲。

「変わりたい」を、行動の変化と取り違えない

無料公開書籍『予測から介入へ』の追加実習章。2026-10-24。原著を調べた独自解説で、ここで紹介する研究を私たちが再実行したものではない。調査範囲・source hash・取得できなかった資料は研究記録に残した。

AIが人の行動変容を支えられるかを知るには、「この会話で変わりたいと思いましたか」と尋ねるだけでは足りない。実際の選択が変わったか、その変化は続いたか、本人にとってどんな結果になったかまで問いを進める必要がある。この難しさを具体的に教えてくれる研究がある。

15分の対話で、何が変わったか

Conrado Eiroa-SolansとMichael Inzlichtは、GPT-4を使ったIntrinsic AIを調べた。方法の中心は、動機づけ面接、英語でMotivational Interviewingと呼ばれる対話の枠組みだった。本人の価値観を探り、向社会的な行動とのつながりを考え、具体的な場面でどうするかを話す。研究者は専門家と一緒に、8段階のsystem promptや対話上の制約を整えた。本文の方法はprompt engineeringであり、要旨の「tuned」という語から独自の重み学習まで行ったと決めつけることはできない。原著

比較相手もGPT-4だった。介入群はIntrinsic AIと15分話し、対照群は通常のGPT-4と自由に話す。AIに話しかけてもらう体験そのものと、特定の対話方法の効果を分けようとした設計だ。

研究では、他者に親切になることの重要さ、成功できるという自信、始める準備について、直後の自己報告に差が見られた。しかし、その差は24時間後には有意と確認されなかった。charityのために認知的な努力を選ぶ課題でも改善は確認されなかった。

ここから「AIでは行動は変わらない」と結論するのも早い。著者は小さい効果の不在まで示せる検出力ではなかったと説明する。また、広い向社会的目標と、寄付のための限定した課題には距離がある。この研究が示すのは、今回の短い対話で観測された範囲だ。反復すれば必ず効くという結論も、まだ得られていない。

要旨と本文の人数を照合する

要旨はN=237と書く。一方、Methodsにはbaseline315人、介入時244人、追跡212人、除外後の解析234人と203人が記されている。この違いの原因を今回の調査だけでは解決できなかった。著者配布本文 §7.1

研究を紹介するときは、この不一致を消さない。「237人で行動が変わった」とまとめれば、人数も結論も取り違える。行動課題の64試行も、64人の独立した参加者ではない。同じ人の反復を別人として数えると、精度を過大に見せてしまう。

本文は公開data/codeと事前登録へのリンクを示している。ただし今回、OSF APIは401、事前登録PDFは403だった。リンクの存在は確認できたが、実packageの取得・license確認・解析再現はできていない。読み物の引用、データの再配布、モデルの学習は、それぞれ別の利用である。

会話エージェントの設計も、一から考える必要はない

Yizhe YangらのCAMIには、状態推定、話題探索、strategy選択、応答生成・選択という分解がある。公開sourceのinfer_state、explore、select_strategy、generate、refineを読むと、「よさそうな返答を出す」という一つの処理を、調べられる小さな判断へ分ける方法が分かる。論文・固定版source

ただし、ここで使われるsimulated clientの発言は現実の人の変化ではない。エージェントが「準備できた」と分類しても、本人が翌日に行動した証拠にはならない。今回はsourceの選択読取と構文解析までで、API対話は動かしていない。明示licenseも確認できていないため、Managerへコピーして組み込んだものではない。

Ben CohenらのMI-TAGSも参考になる。MITIの発話分類やglobal score、CLEARのclient言語タグを持つdemonstration transcriptsは、会話の質を測る候補になる。ただし、会話の質、行動の完了、持続、苦しみの低減は、それぞれ対応する観測が必要だ。公開repoのsampleとaccess requestの案内を、full datasetの取得済み状態へ置き換えてはいけない。論文・著者repo

Managerでは、何を先に確かめるか

Managerは、行動変容を通じて苦しみを終わらせることを目指す研究開発である。その目標の大きさは、途中で測る数値の意味を広げてよい理由にはならない。

現在のCostello資料によるモデル研究は、事前の自己報告値と実験条件から、事後の自己報告値を予測する有限実験だ。128件で一つのLoRAを学習するところまでは終わった。学習前モデルや単純な統計予測よりよいかは、まだ判定していない。まして、本人に働きかけて苦しみが減った実証ではない。実学習記録

次の評価では、主要な誤差指標を先に固定し、予測できなかったケースも分母に残す。改善しなければ、それを結果として公開する。人を対象にする段階では、本人が選ぶ具体的な行動に対して、行動する機会、実際の選択、後日の継続、本人への負担や害を測る。特定の信仰を前提にせず、本人の目標と実際の結果を確かめる。

読者にも同じ練習ができる。興味のある論文を一つ選び、次の表を埋めてほしい。空欄を想像で補わず、未測定や未取得と書くことも成果になる。

読む場所	自分の言葉で書くこと
Methods	誰が、何を選び、何と比較されたか
Measures	発言、動機、行動、生活上の結果のどれを測ったか
Participant flow	最初の人数、解析人数、追跡人数はそれぞれいくつか
Results	直後と追跡で、何が確認され、何が確認されなかったか
Availability	実際に取得したdata/codeと、その利用条件は何か

既存研究から学ぶとは、成功した数字を集めるだけではない。何が変わらなかったのかまで読み、次に確かめる問いを小さく、測れる形にすることでもある。

同じ発話が十行あるとき — 会話データを評価に使う前に

無料公開書籍『予測から介入へ』の追加実習章。2026-10-24。AnnoMIの公開資料を取得し、行数・発話・対話・注釈者の対応を調べた独自解説である。モデルの成績や人への介入効果を新しく測った章ではない。

まず、一行が何を表すかを調べる

会話モデルを改善したいとき、既存の専門家注釈を使える資料は貴重だ。AnnoMIは、Zixiu Wuらが公開した動機づけ面接のデータセットである。133のデモ対話を専門的に書き起こし、会話中の振る舞いに注釈を付けている。2022原著

公開リポジトリにはsimple版とfull版がある。今回取得した固定版では、simple版が9,699行、full版が13,551行だった。同じ資料の二つの版なのに、なぜ行数が違うのだろう。

ここで「full版は学習例が増えている」とすぐ判断すると、評価の単位を間違える。まず、transcript_idとutterance_idを組にして数える。前者は対話、後者はその中の発話を区別するための列である。

```
import csv
from collections import Counter

with open("AnnoMI-full.csv", encoding="utf-8-sig", newline="") as f:
    counts = Counter(
        (row["transcript_id"], row["utterance_id"])
        for row in csv.DictReader(f)
    )
print(len(counts))
print(Counter(counts.values()))
```

今回の固定版で得られるのは、uniqueな発話9,699、注釈が一つの発話9,271、注釈が十個ある発話428という対応だ。428発話は7対話に含まれている。増えた3,852行は、同じ発話への追加注釈だった。固定版リポジトリ

人、対話、発話、注釈者は、それぞれ違う単位を持つ。精度や信頼区間を読む前に、この対応を確認したい。

元の著者が解いている部分を、そのまま学ぶ

2023年の拡張論文は、7対話を十人の専門家で注釈し、評価者間の一致を調べたと説明する。その他の126対話には一人ずつが注釈した。解析と実験では、複数の注釈を多数決へ集約している。元の著者が13,551行を独立した発話として評価した、と読み違えてはいけない。拡張原著

私たちは、simple版の二つの高level labelについて、複数注釈の428発話をfull版と照合した。simple版のラベルがfull版の最多票候補から外れるものはなかった。同数票はtherapist側の分類で4発話、client側の分類で10発話あった。

最初の分類研究なら、この既存simple版を使う方法を検討できる。fine-grainedな注釈が必要になった段階で、full版の不一致や同数票をどう扱うかを決めればよい。必要な用途を決める前に、独自の集約方法を増やす必要はない。

分類のラベルは、何を意味するか

therapistの発話には、reflection、question、therapist inputなどの分類がある。clientの発話にはchange、neutral、sustain talkの分類がある。これらは、会話の中で何が表現されたかを調べるための専門家注釈だ。

ある発話がchange talkと分類されても、その人が翌日に何をしたかは、このラベルからは分からない。会話のhigh/low qualityも、治療効果が高かった群と低かった群という意味ではない。資料は、MIのよい例・よくない例を示すデモ映像に由来する。

このデータを直接使うなら、まず会話内の分類やannotation fidelityという問いに合わせる。その後の行動、持続、苦しみの低減については、対応する別の観測が必要になる。

評価したい一般化に合わせて分割する

拡張論文のbaselineは、発話のラベルで層別した5-fold cross-validationを使う。原著と同じ結果を再現するなら、その方法と条件をたどる。

一方、新しい対話への一般化を調べたい場合は、同じ対話や同じ映像からの発話が学習側と評価側に分かれない設計を考える。同じ発話への注釈を別splitへ置くことも避ける。今回の資料では133対話が119の映像URLに対応しており、対話だけを分けても映像を共有する可能性がある。

それでも、新しい人物への一般化まで確認できたことにはならない。今回はactorの同一性を調べておらず、外部の人物情報にも結び付けていない。利用できる分割軸と、分からない軸を明記することが評価の一部になる。

利用条件は、宣言の出典まで残す

取得したrepoにはLICENSE fileがなく、GitHubのlicense metadataもnullだった。一方、2023拡張論文のData Availabilityは、full版をPublic Domain Licenseで公開すると明記している。この宣言も一次資料として記録する。

ファイルがないことだけで利用禁止と判断せず、存在する利用宣言を読む。ただし、Public Domainという記述を勝手に別のCC0契約へ書き換えたり、原動画を含む全素材のあらゆる権利が保証されたと主張したりもしない。今回行ったのは、資料参照と私有のschema・集計監査である。会話本文や映像を本へ転載していない。

モデルを作る前に、すでにあるデータと方法をここまで理解できる。どのラベルを借り、どの単位で分け、どんなbaselineと比較し、どこまでの結論にとどめるか。その判断を公開することも、次に学ぶ人の時間を節約する研究成果になる。

学習が動いても、予測が改善したとは限らない

無料公開書籍『予測から介入へ』の実習章。2026-10-24。公開研究の数値データを使った、一つのLoRAの学習と比較の実記録である。今回の候補は採用していない。

何を学ばせたのか

Costelloらの研究資料には、対話前後の本人報告confidenceと、対話の割付条件がある。私たちは、対話前の値と割付条件の二つから、対話後の値を予測する小さな研究を作った。原著の説得文をモデルへ学習させる実験ではない。

基底モデルにはQwen3-0.6B、学習には既存のPEFT/TRLを使った。独自trainerを作らず、事前に選んだ128件で一つのLoRAを学習した。32回のoptimizer処理が完了し、保存されたadapterの数値も検査した。学習記録

ここまでで分かるのは、学習して保存する経路が動いたことだ。予測の価値は、別の比較で確かめる。

大きなモデルの前に、小さなルールを置く

比較には、対話前の値をそのまま予測にするpersistence、学習128件の平均、同じ128件からfitしたOLSを使った。何も予測しないNO_ACTIONの棄権も別に残した。これらの意味を混ぜず、学習前モデルと一つのadapterを加えた。

モデルへの入力は二つのfeatureだけなので、可能な組合せは102個ある。同じ入力への生成を繰り返す代わりに、各モデルで102条件を一回ずつ生成し、その結果を元の全参加者へ対応付けた。評価の分母は、development584件とevaluation762件のままである。

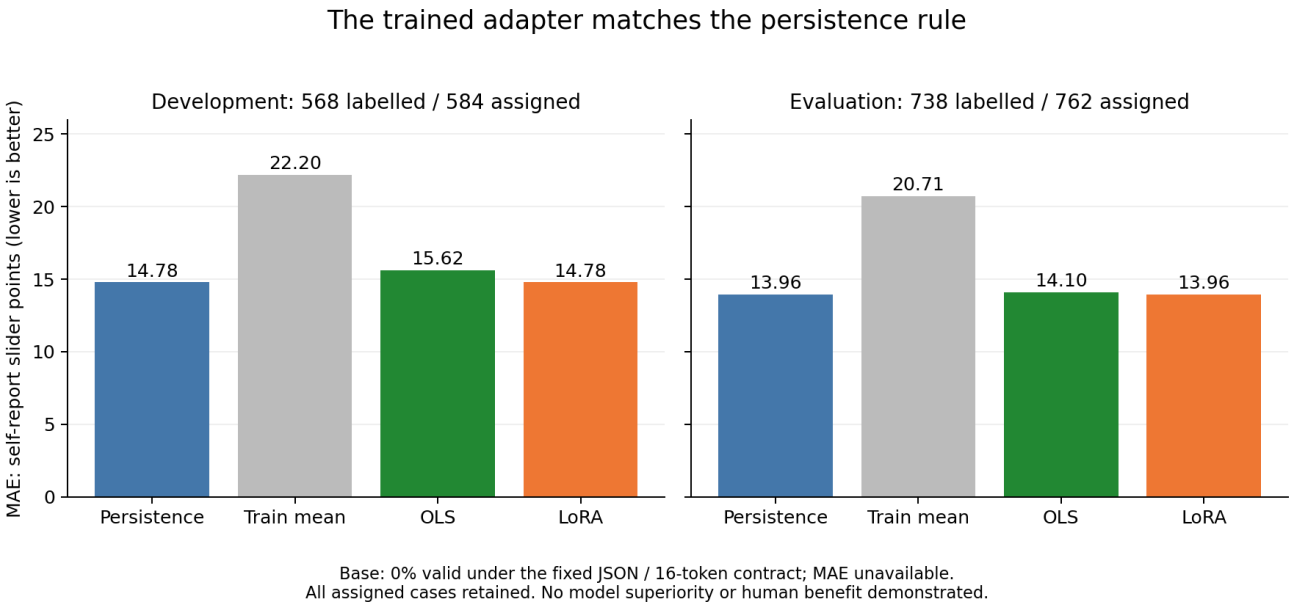
生成処理には個票IDも正解値も渡していない。両モデルの生成が終わった後に記録を固定し、その後で正解値と照合した。生成はgreedy、最大16 new tokens、一つの整数JSON、出力修復なし。結果がよくなるまで同じ評価へ合わせ直す手順は作っていない。

得られた結果

adapterは全条件で形式の正しいJSONを返した。しかし、102条件すべてで「対話前の値をそのまま返す」予測になっていた。割付条件がどちらでも同じルールである。

方法	development MAE	evaluation MAE
事前値をそのまま返す	14.778169	13.962060
train128平均	22.202410	20.711255
train128 OLS	15.624753	14.101310
学習したLoRA	14.778169	13.962060

MAEは小さいほどよい。正解値があるのはdevelopment568件、evaluation738件で、残る16件と24件の欠測を別に保持した。単位は0 – 100の本人報告slider pointsである。



図は有効な点予測のある4方法を示す。baseは出力形式不成立、NO_ACTIONは意図した棄権で、どちらも棒グラフの外に保持する。

学習前モデルは、この固定したJSON/16-token条件で全102出力がINVALIDだった。したがって、有効予測のMAEは計算できない。これを0点や100点の実測誤差へ書き換えたり、LoRAの予測能力が学習前モデルより高いという順位を付けたりはしない。別の出力条件ならどうなるかは、今回の比較からは分からない。

指標を変えて、成功に見せない

OLSはRMSEではpersistenceより小さかった。しかし、主要指標は学習前にMAEと決めていた。結果を見てから、成績のよい指標へ乗り換えることはしない。

LoRAとpersistenceの誤差差は0だった。この0は同じ予測を返していたことによるもので、治療効果や苦しみの低減について同等だという意味ではない。OLSとのMAE差のbootstrap区間も0を含んだ。さらに、学習前モデルの有効予測がないため、全モデルが同じ分母でcompleteという事前条件も満たしていない。

公開資料は原著解析や品質確認で曝露済みであり、完全に未見の評価とも呼べない。独立の検算では保存済み予測から数値を照合したが、それでこの限界が消えることもない。全結果と検証記録

この結果から、次に何を選ぶか

今回の判断は明確だ。このadapterを採用する理由は得られなかった。同じevaluationへ合わせて学習をやり直さず、この有限実験を閉じる。形式を守れることと、強い単純ルールを超えることを別に確かめられたのは、次の設計に使える結果である。

会話の質を調べるなら、AnnoMIなどに専門家注釈がある。既存のsimple版や評価手法を理解し、目的に合うものを借りる。会話データの実習章では、その前に確認する単位と分割を扱った。

人の行動変容を支える価値は、その人が選ぶ具体的な行動、後日の継続、負担や害、本人への結果によって別に調べる。今回、その新しい参加者や介入はゼロである。数値予測の成績を、その実証の代わりにはしない。

既存のモデル、学習ライブラリ、公開データ、統計手法を組み合わせると、小さな資源でもここまで確かめられる。足りない能力を言葉にし、採用しない判断まで公開することも、透明な研究開発の一部になる。